

好的，我直接输出 Markdown 格式，你可以复制保存为 `.md` 文件，也可以用 Typora / VS Code / Obsidian 导出 PDF。

华为昇腾310B端侧AI推理优化实习指导文档

目标

将华为实习经历打造为秋招中的核心竞争力。


不要将自己定位为：

模型部署工程师

而应该定位为：

端侧AI推理优化工程师 / NPU性能优化工程师 / AI计算优化工程师

核心能力链：




最终形成：


懂硬件、懂嵌入式、懂AI计算优化的端侧智能工程师。

一、当前华为实习工作的正确定位

当前真实工作流程

你的工作链路：





因此你的核心不是：

“把模型跑起来”

而是：

让模型在昇腾310B NPU上跑得更快、更省资源。

二、秋招中的岗位定位

推荐方向：

1. 端侧AI推理优化工程师

关键词：

- Ascend310B
- CANN
- ONNX
- OM

- Profiling
- Operator Fusion
- Quantization
- Kernel Optimization

2. NPU性能优化工程师

关键词：


- AI Compiler
- Graph Optimization
- Operator Optimization
- Hardware Acceleration

3. 嵌入式AI软件工程师

结合你的：

- 禾赛车规MCU
- ESP32 FreeRTOS
- ROS C++
- 华为昇腾

形成：



这是你的独特优势。

三、实习期间最高优先级积累方向

Priority 1：形成完整性能优化闭环



这是最重要的。

不要只做：

模型转换



运行

而要形成：

发现问题



Profiling分析



定位瓶颈



提出优化方案



代码实现



性能提升验证

建议记录指标

每个优化案例记录：

指标	优化前	优化后
推理延迟	xx ms	xx ms
算子数量	xx	xx
TOP耗时算子	xxx	xxx
NPU利用率	xx%	xx%
显存/内存占用	xx	xx

最终简历：

基于CANN Profiling工具分析昇腾310B模型执行瓶颈，定位关键耗时算子，通过计算图优化和算子融合降低模型推理延迟。

Priority 2: 深入一个算子融合案例



这是区分普通实习生和AI优化工程师的关键。

算子融合原理

例如：

优化前：

```
Conv
|
BatchNorm
|
ReLU
```

三个算子：

```
Kernel1
Kernel2
Kernel3
```

存在：

- 多次Kernel启动
- 中间Tensor写回DDR
- 数据重复搬运

优化后：

```
Conv + BN + ReLU Fusion
```

减少：

- Kernel Launch
- Memory Access
- Tensor Copy

提升：

- NPU利用率
- 推理速度

建议深入：

- Operator Fusion
- Graph Rewrite
- Constant Folding
- Dead Node Elimination

- Shape Optimization

Priority 3: 单算子开发 ★★★★★

这是非常有含金量的方向。

很多学生：

会：

PyTorch
ONNX
TensorRT

但是不会：

为什么这个算子慢？
如何优化？
如何让NPU更高效执行？

单算子开发流程

算子定义

↓

输入输出Shape设计

↓

kernel实现

↓

Memory优化

↓

性能Benchmark

↓

精度验证

重点理解：

NPU计算特点

包括：

- Cube计算单元

- Vector计算单元
- Cache结构
- DDR访问
- DMA搬运

Priority 4: 量化策略优化 ★★★★★

目标：

降低计算量。

典型：

FP32

↓

FP16

↓

INT8

PTQ流程

Post Training Quantization

FP32模型

↓

Calibration Dataset

↓

统计激活范围

↓

生成scale/zero point

↓

INT8模型

重点优化：

1. Calibration数据选择

错误：

随机数据。

正确：

覆盖真实输入分布。

2. 混合精度

不要：

全部INT8。

而是：

Conv：
INT8

Attention：
FP16

Softmax：
FP32

达到：

速度提升

同时：

保持精度。

Priority 5: ONNX计算图优化 ★★★★★

不要只会：

onnx → om

要理解：

ONNX Graph

↓

优化

↓

OM

关注：

- Node Fusion
- Graph Rewrite
- Constant Folding
- Operator Replacement

Priority 6：端侧推理工程化 ★ ★ ★ ★

结合你的嵌入式背景。

建议做：

C++推理框架封装。

结构：

Application

↓

Inference API

↓

Model Manager

↓

ACL Runtime

↓

Ascend310B

功能：

- 模型加载
- Tensor管理
- 输入输出管理
- 推理接口

- 性能统计
- 异常处理

四、实习期间建议主动争取的任务

第一优先级

负责一个完整模型优化闭环

例如：

ONNX模型

↓

Profiling

↓

发现瓶颈

↓

算子优化

↓

重新编译OM

↓

性能提升

最终得到：

一个可以讲30分钟的面试案例。

第二优先级

一个自定义算子/融合案例

例如：

- LayerNorm
- Attention
- Resize
- Activation

最好有：

优化前：

50ms

优化后：

30ms

提升40%

第三优先级

一个量化优化案例

例如：

FP32

↓

INT8

↓

Latency下降30%

↓

Accuracy下降<1%

五、华为实习简历最终推荐写法

华为技术有限公司

端侧AI推理优化实习生

参与基于昇腾310B NPU平台的端侧深度学习模型部署与推理性能优化，负责ONNX模型分析、OM转换、计算图优化、算子优化及量化策略调优。

- 基于Ascend CANN工具链完成ONNX模型到OM模型转换，通过Profiling工具分析模型执行流程，定位关键耗时算子及性能瓶颈。
 - 针对昇腾310B NPU计算特点，开展计算图优化与算子融合优化，减少Kernel调度及中间Tensor数据搬运，提高模型推理效率。
 - 参与高性能算子开发与优化，包括算子接口设计、计算逻辑实现、性能测试和精度验证。
 - 针对不同网络结构设计FP16/INT8混合精度量化策略，通过校准数据优化和精度回归测试，实现模型压缩与推理加速。
 - 完成优化后模型在ARM64 Linux边缘设备上的部署验证，建立模型精度、推理时延和资源占用之间的优化闭环。
-

六、面试重点准备问题

1. 为什么算子融合可以降低延迟？

答案：

不是因为减少计算量。

主要原因：

- 减少Kernel启动次数
- 减少DDR访问
- 减少中间Tensor读写
- 提升计算密集度

2. ONNX为什么需要转换OM？

回答：

ONNX是通用模型交换格式。

OM是昇腾针对NPU优化后的执行模型。

转换过程：

ONNX

↓

图优化

↓

算子映射

↓

内存规划

↓

OM

3. INT8为什么更快？

因为：

- 数据量减少
- 内存带宽压力降低
- NPU整数计算效率更高

但是：

需要解决：

- 量化误差
- 精度下降

七、你的最终技术画像

你的目标不是：

会调用AI模型的嵌入式工程师

而是：

理解芯片底层资源，掌握嵌入式系统开发，同时具备AI计算图优化和NPU性能调优能力的端侧智能工程师。

八、未来适合岗位

AI芯片方向

- 华为昇腾
- 海思
- 寒武纪

自动驾驶方向

- 地平线
- 大疆
- 小米汽车
- 比亚迪智能驾驶

机器人方向

- 边缘计算
- AI机器人平台

AIoT方向

- 智能终端
- 端侧大模型

最终建议

你的实习剩余时间不要追求“做更多模块”。

最有价值的是：

拿一个模型，完成一次完整的端侧AI性能优化闭环，并留下量化指标。

一个优秀案例：

ONNX模型

↓

Profiling分析

↓

发现瓶颈

↓

算子融合/量化/kernel优化

↓

OM重新编译

↓

310B部署

↓

Latency降低xx%

这会成为你秋招中最有竞争力的一段经历。