

刘宇航

嵌入式软件开发 | 端侧 AI / NPU 推理优化

13298775026 | 2640606471@qq.com

核心技术：C / C++ / Python | Linux / FreeRTOS / AUTOSAR Classic | Cortex-R5 / ESP32-S3 | Ascend CANN / ONNX / CCE-C | ROS / Protobuf / gRPC | CMake / Git / Docker

教育经历

哈尔滨工业大学 | 信息与通信工程 | 学术型硕士（推免）

2024.09 - 2027.06

哈尔滨工业大学 | 电子信息工程 | 工学学士

2020.09 - 2024.06

实习经历

华为技术有限公司 | 端侧 AI 推理优化工程师

2026.07 - 至今 | 东莞

ICT BG 无线产品线 / 基带开发与芯片验证部 / AI 下行技术开发组

- 模型部署与 Profiling**：面向 5G 基站物理层 AI 信道估计，负责 Transformer 类模型在 Ascend 310P3 NPU 上的端侧部署与性能优化；基于 CANN 完成 ONNX→OM 转换、推理验证及性能评估，使用 msprof 分析算子耗时、硬件资源利用与数据搬运，定位计算、调度及访存瓶颈。
- 计算图优化**：针对模型转换后的动态 Shape 推导与冗余计算，结合固定输入特性实施静态 Shape 推导、常量替换及冗余节点消除，减少运行时计算与调度开销。
- 混合精度与方案评估**：□□ Transformer 核心模块评估算子近似及 FP16/INT8 混合精度方案，结合理论计算量、模型精度和 NPU 实测性能分析优化收益；定位额外 Cast 破坏 CANN 算子融合链路的问题，并据实测结果完成方案取舍。
- 算子融合与 Kernel 开发**：针对 Attention 多算子串联造成的中间数据频繁搬运，基于 CCE-C 设计融合算子与自定义 Kernel，完成算子接口、计算划分与片上数据复用设计；结合 310P3 架构采用多核 Head 并行、Ping-Pong 双缓冲及 GM→片上缓存流水，提高 AI Core 执行效率。
- 优化结果与精度闭环**：通过余弦相似度、MSE 及复数相关性验证优化前后输出一致性；综合多种优化手段使计算图节点数降低 37%，端侧推理时延由 572 μ s 降至 320 μ s（降低 44.1%），未引入明显精度损失。

上海禾赛科技有限公司 | 嵌入式软件工程师

2026.04 - 2026.07 | 上海

软件部 / 雷达功能与功能安全组

- 车规平台与 AUTOSAR**：基于芯驰 E311X 双核 Cortex-R5、AUTOSAR Classic 与 ETAS BSW/RTA-OS 参与新一代车载激光雷达 MCU 软件及 ISO 26262 功能安全机制开发，参与小米、理想、吉利等量产项目；熟悉 ASW/RTE/BSW/MCAL/CDD 分层、OS 调度及多核分区。
- 功能安全与诊断开发**：参与运行模式状态机、故障诊断、参数配置、芯片监控及 Flash 数据可靠性模块；独立完成入口电压、Rx Start Signal、ADC 诊断、Program/Flash CRC、PC1300 SPAD Chip Monitor 等功能的需求拆解、嵌入式 C 开发与实机验证，掌握 UDS/DTC/DEM 诊断链路及故障注入、去抖/恢复策略。
- 调测工具与问题定位**：完成 PC1300 遥测 UDP 协议改造，在包头新增 EfuseId/Chip ID 并升级协议版本，解决 preDV 多雷达并发监控设备区分问题；开发芯片电源域 PTC 调试指令，实现上位机远程通道切换、MCU ADC 回读及阈值判定。
- 量产交付**：使用 IAR、ADS/Tasking、CMake/Build.bat、串口/日志、抓包及故障注入完成集成调试与问题复现，遵循 MISRA 向 C 编码、MemMap 等工程约束；独立负责雷达 MCU APP/BOOT Release/Factory 软件包发布。

项目经历

基于昇腾边缘计算平台的锂电池寿命预测系统

2024.09 - 至今

Ascend 310B4 / CANN / PyTorch / ONNX / ACL Lite / ARM64 Linux

- 算法与端侧全链路**：独立完成“算法研发→模型转换→昇腾编译→板端适配→效果验证”全流程；基于 NASA 数据集提取 11 维退化特征，以 GRA 筛选强相关特征、PCA 去冗余并构建 LSTM 时序模型，五组电池平均 RMSE ≤ 0.004 Ah、准确率 $>99.8\%$ 、EOL 误差 <2 个循环，相关方法以第一作者发表 EI 会议论文。
- 模型转换与静态图适配**：完成 .pth→ONNX→OM 转换，采用固定 Shape、opset 12 将 LSTM 动态序列固化为静态图；显式暴露 h0/c0 并跨推理迭代传递，配合固定滑动窗口恢复时序依赖。
- ARM64 板端部署**：在 Atlas 200I DK A2 (Ascend 310B4) 完成 CANN 环境、ATC 编译与 aarch64 依赖适配，基于 ACL Lite 封装资源初始化、OM 加载/执行及释放流程。
- 推理工程化**：搭建“预处理→推理→指标评估→可视化落盘→资源释放”流水线，适配 Linux headless 环境并支持命令行参数化多型号切换。

嵌入式负责人 / ESP32-S3 / FreeRTOS / MQTT / HTTP / OTA

- **RTOS 架构与并发**：独立完成终端固件，按职责拆分网络维护、遥测上传、HTTP、传感器、GPS、OLED 等任务并进行双核绑定；使用 Queue 解耦采集与上传、EventGroup 管理 Wi-Fi/MQTT 状态、Mutex 保护共享资源并利用优先级继承抑制优先级反转。
- **外设与通信**：基于 GPIO/单总线、UART、I2C 驱动 DHT22、HX711、NEO-6M、OLED；通过 MQTT (Alink/QoS0) 上报遥测，ESP32-CAM 采用 HTTP + OV2640 I2S/DMA + PSRAM 双帧缓冲传输 JPEG，实现控制流与图像数据流分离。
- **OTA 与离线可靠性**：设计 Web、局域网推送、MQTT 下发固件地址三种 OTA 通道；使用 RAM 环形缓存实现断网数据存恢后限速，通 NVS 持久化云端热更新参数。
- **实时性优化**：将阻塞轮询重构为非阻塞状态机与独立 FreeRTOS 任务，规避 WDT 超时复位；将 GPS 从软件串口迁移至硬件 UART 并扩大接收缓冲，降低串口丢包。

面向机器人与自动驾驶的分布式通信与性能监控系统

2024.09 - 2025.06

C++ / Linux / ROS / Protobuf / gRPC / Qt / CMake / Docker

- **ROS-Protobuf 通信层**：基于 C++ 模板偏特化、SFINAE 与 roscpp traits/serialization 扩展序列化层，为 Protobuf 消息注入统一序列化路径与类型元信息，使 ROS Topic 在不改变发布/订阅接口的情况下直接承载任意 Protobuf 消息，并封装为 CMake 可集成静态库。
- **采集与分布式服务**：基于继承/多态、智能指针和工厂模式设计可插拔 Linux 指采集架，通 /proc 获取 CPU、内存、网络及系统负载；使用 gRPC + Protobuf 构建客户端流式上报、服务端流式订阅及采样参数动态下发。
- **可视化与部署**：基于 Qt Model/View 构建集群性能监控界面；使用 CMake、Docker/Dockerfile 与 Shell 搭建 ROS-Noetic 运行环境和多模块部署，并通过 stress 负载验证采集准确性及告警链路。

科研成果

- **论文 / 知识产权**：第一作者 EI 会议论文 ×2 (IEEE PHM-Xian、ICEDCA 2026)，第二作者 EI 会议论文 ×1 (ICEEDP 2024)；第一作者发明专利 ×2 (已受理)，软件著作权 ×1。
- **硕士课题**：面向 ReRAM 存内计算 SAF、器件变异等非理想特性研究算法级精度补偿，在 MLP/LeNet-5/VGG-8 与 MNIST/CIFAR-10 上验证，中高缺陷率场景最高恢复 20.56 个百分点推理精度。
- **科研项目**：北京某研究所项目子模块负责人，将测试点优化建模为约束多目标组合优化问题并设计 IBPS-GA，实现测试点数量减少 50%、成本降低 56.4%，故障检测/隔离率均 >90%。

荣誉与其他

竞赛荣誉：全大生物大（杯）全一等 | ICAN 全国三等奖 | “互联网+”黑龙江省 | “AI for Future”十佳团队 | 首届“星闪杯”优秀奖

学生工作：本科/研究生班长 | 本科生第一党支部支部委员 | 研究生会文体活动部部长

英语能力：CET-4 625 | CET-6 611